

analisi_crittoanalitica_crittogramma

May 28, 2026

1 Analisi crittoanalitica del crittogramma

Questo notebook documenta l'analisi crittoanalitica del crittogramma fornito come assignment.

L'obiettivo è raccogliere evidenze statistiche e strutturali per orientare l'indagine sul cifrario utilizzato, senza assumere a priori una soluzione. L'analisi considera le principali famiglie di cifrari affrontate nel corso:

- cifrari a trasposizione;
- cifrari a sostituzione monoalfabetica;
- cifrari polialfabetici, con particolare attenzione a Vigenère;
- cifrari a digrammi, con particolare attenzione a Playfair.

L'intero processo è svolto in **Jupyter Notebook**, così da rendere riproducibili caricamento dei dati, calcoli, grafici e conclusioni.

1.1 1. Caricamento e normalizzazione del crittogramma

Il crittogramma viene letto dal file `crittogramma.txt`.

La normalizzazione mantiene solo le lettere A-Z, eliminando spazi, a capo e caratteri non alfabetici. Questa operazione è necessaria per rendere coerenti frequenze, n-grammi, indice di coincidenza e test sulle sequenze ripetute.

Lunghezza testo normalizzato: 1448

Prime 100 lettere: VIANPGMIIMQCTLQVPQRCFINUVOLUNTICGZSYNAQYPGFIMNTDNGGBFIMNIOVOH
INLMIVYRCLTLHNQBRQCTORCXYCGATIMCRIHSBRQ

Ultime 100 lettere: INPFDNHQYMGSBVYAMCRICQBCKCHLNTDPCSKUNMTNIHDPNPHYHENQCTBLLNYV
CLHYLWIFIGNALHMTDIQVPQRCFINUVONTLBYZYNP

Lettere presenti: ABCDEFGHIKLMNOPQRSTUVWXYZ

Lettere assenti: ['J']


1.2 2. Osservazione preliminare sull'alfabeto

Una prima evidenza riguarda l'alfabeto effettivamente osservato nel crittogramma.

L'assenza della lettera **J** non è un dettaglio marginale. Nei cifrari classici può indicare:

- uso di un alfabeto ridotto a 25 lettere;
- fusione I/J;
- impiego di una matrice 5×5 ;
- compatibilità con cifrari a digrammi come **Playfair**.

Questo elemento non dimostra da solo l'uso di Playfair, ma costituisce un indizio strutturale importante da verificare con analisi specifiche sui digrammi.



1.3 3. Frequenze dei monogrammi


L'analisi delle frequenze delle singole lettere è il primo passo della crittoanalisi statistica.

- In un cifrario a **trasposizione**, le lettere non cambiano: la distribuzione dovrebbe restare simile a quella della lingua naturale.
- In una **sostituzione monoalfabetica**, la forma della distribuzione tende a conservarsi, ma cambiano le etichette delle lettere.
- In un cifrario **polialfabetico** o a **digrammi**, la distribuzione può risultare più appiattita.

[4]:

	Lettera	Conteggio	Freq_%
13	N	133	9.185083
11	L	122	8.425414
8	I	114	7.872928
2	C	96	6.629834
12	M	95	6.560773
24	Y	80	5.524862
7	H	74	5.110497
16	Q	69	4.765193
6	G	66	4.558011
0	A	58	4.005525
19	T	58	4.005525
20	U	50	3.453039
17	R	50	3.453039
21	V	50	3.453039
3	D	48	3.314917
1	B	47	3.245856

15	P	45	3.107735
10	K	42	2.900552
5	F	38	2.624309
14	O	31	2.140884
25	Z	22	1.519337
4	E	17	1.174033
22	W	16	1.104972
18	S	16	1.104972
23	X	11	0.759669
9	J	0	0.000000



1.4 4. Confronto con italiano e inglese

Il confronto con le distribuzioni di frequenza dell'italiano e dell'inglese deve essere interpretato con cautela.

Il confronto lettera-per-lettera è più significativo per l'ipotesi di trasposizione, perché la trasposizione conserva le lettere del testo originale. Per la sostituzione monoalfabetica, invece, è più informativo il confronto per **ranking**, cioè la forma della distribuzione ordinata dalla lettera più frequente alla meno frequente.

Per supportare questo confronto vengono usati alcuni **indici di similarità e distanza**. Senza entrare troppo nel dettaglio matematico, possono essere letti così:


- **Differenza assoluta:** misura lo scostamento complessivo tra due profili di frequenza. Valori più bassi indicano maggiore vicinanza.
- **Distanza euclidea:** interpreta le frequenze come coordinate in uno spazio multidimensionale. È utile per stimare quanto due distribuzioni siano distanti in termini geometrici.
- **Correlazione:** misura se due profili “si muovono insieme”. Se una lettera è relativamente frequente in un profilo e tende a esserlo anche nell'altro, la correlazione cresce.

- **Cosine similarity:** confronta soprattutto la forma complessiva delle distribuzioni. È utile quando interessa capire se due profili hanno un andamento simile, anche senza pretendere una sovrapposizione perfetta.

Dal punto di vista operativo, questi indici non identificano direttamente il cifrario, ma aiutano a capire se il crittogramma mantiene ancora un'impronta linguistica riconoscibile oppure se tale impronta è stata attenuata dalla cifratura.

[6]:

	Lingua	Diff_assoluta	Dist_euclidea	Correlazione	Cosine_similarity
0	Italiano	76.586354	19.770940	0.275081	0.707676
1	Inglese	74.371271	18.945316	0.143689	0.701107



1.5 5. Entropia e Indice di Coincidenza

L'**Indice di Coincidenza (IC)** e l'**entropia** sono due indicatori utili per descrivere il comportamento statistico del testo cifrato.

1.5.1 Indice di Coincidenza

L'IC misura, in modo intuitivo, quanto spesso due lettere scelte nel testo tendono a coincidere. Per un informatico può essere letto come un indicatore di **ridondanza** o di **concentrazione** della distribuzione:

- se tutte le lettere compaiono con frequenza simile, l'IC è basso;
- se alcune lettere compaiono molto più spesso di altre, l'IC aumenta;
- un testo naturale tende ad avere IC più alto di una sequenza casuale, perché le lingue hanno frequenze caratteristiche.

Per questo motivo, l'IC è utile per distinguere tra testi molto appiattiti statisticamente e testi che conservano ancora una struttura linguistica.

1.5.2 Entropia

L'entropia misura quanta **varietà** o **imprevedibilità** c'è nella distribuzione dei simboli:

- entropia alta significa distribuzione più uniforme e quindi meno prevedibile;
- entropia bassa significa che alcune lettere dominano maggiormente, quindi il testo presenta una struttura più marcata.

In questa analisi IC ed entropia vengono letti insieme: l'IC evidenzia quanto il testo si discosta dalla casualità in termini di ripetizione dei simboli, mentre l'entropia indica quanto il profilo delle frequenze è concentrato o distribuito.

Valori di riferimento:

- testo uniforme su 26 lettere: circa $1/26 = 0,0385$;
- testo uniforme su 25 lettere: circa $1/25 = 0,0400$;
- italiano/inglese naturale: valori sensibilmente più alti, tipicamente nell'ordine di $0,066-0,074$.

Un IC intermedio indica che il testo non è casuale, ma che le frequenze sono più appiattite rispetto a una lingua naturale.

[8]:		Indicatore	Valore
0		IC osservato	0.052354
1	IC casuale uniforme 25 lettere		0.040000
2	IC casuale uniforme 26 lettere		0.038462
3		IC inglese tipico	0.066700
4		IC italiano indicativo	0.073800
5		Entropia osservata	4.408461
6	Entropia uniforme 25 lettere		4.643856
7	Entropia uniforme 26 lettere		4.700440

1.6 6. Analisi dei digrammi e trigrammi

I digrammi e trigrammi permettono di osservare pattern ripetuti e vincoli strutturali non visibili nei soli monogrammi.



Questa analisi è particolarmente importante nel caso di Playfair, perché l'unità di cifratura è il digramma.

	Digramma	Conteggio
0	FI	20
1	NT	19
2	RC	18
3	LH	18
4	NP	16
5	IM	15
6	NM	15
7	LB	15
8	AN	14
9	IN	13
10	VO	13

11	UN	13
12	CL	13
13	AI	13
14	LN	13
15	TL	12
16	HI	12
17	NL	12
18	LY	12
19	CK	12
20	VD	12
21	CT	11
22	QR	11
23	MN	11
24	NG	11
25	IF	11
26	GN	11
27	HY	11
28	VI	10
29	IA	10

	Trigramma	Conteggio
0	FIN	7
1	GVD	7
2	QZM	6
3	QVP	5
4	QRC	5
5	INU	5
6	VOL	5
7	IMN	5
8	LWI	5
9	LNy	5
10	NTL	5
11	TLB	5
12	UGV	5
13	QCT	4
14	VPQ	4
15	PQR	4
16	RCF	4
17	CFI	4
18	NUV	4
19	UVO	4
20	FIM	4
21	LHN	4
22	HNQ	4
23	WIF	4
24	ANM	4
25	IFI	4
26	RCU	4

27	LLB	4
28	ZMG	4
29	KUN	4



1.7 7. Test Playfair: digrammi doppi sliding e allineati

Per valutare l'ipotesi Playfair è necessario distinguere tra:

- digrammi **sliding**: coppie consecutive 0-1, 1-2, 2-3, ...
- digrammi **allineati**: coppie effettive di cifratura 0-1, 2-3, 4-5, ...

Nel Playfair standard, il testo viene cifrato a coppie. Di conseguenza, un digramma cifrato allineato

composto da due lettere uguali dovrebbe essere anomalo. La presenza di un doppio in modalità sliding, invece, non è sufficiente per escludere Playfair, perché quella doppia potrebbe trovarsi a cavallo tra due digrammi effettivi.


La tabella seguente confronta quindi tre viste:

- i doppi trovati con finestra mobile;
- i doppi allineati assumendo offset 0;
- i doppi allineati assumendo offset 1.

Questa distinzione è importante perché, in ottica Playfair, non conta soltanto **quanti** doppi esistono, ma anche **dove** compaiono rispetto alla segmentazione a coppie del crittogramma.

```
[11]:
```

	Digramma	Sliding	Allineati_offset_0	Allineati_offset_1
6	LL	9	8	1
0	AA	4	4	0
3	GG	3	2	1
2	CC	3	3	0
9	QQ	3	3	0
7	NN	2	2	0
5	II	2	1	1
4	HH	2	2	0
1	BB	1	1	0
8	PP	1	1	0
10	TT	1	1	0
11	UU	1	1	0



1.8 8. Disposizione dei digrammi doppi nel crittogramma

Per l'ipotesi Playfair, una semplice heatmap delle coppie allineate può essere utile, ma non è sempre la rappresentazione più chiara. In questa analisi è più informativo osservare la **disposizione dei**

digrammi doppi lungo il crittogramma.

L'obiettivo è passare da una lettura puramente aggregata a una lettura spaziale:

- la timeline dei doppi **allineati** mostra dove compaiono le anomalie rispetto alla segmentazione principale;
- la timeline dei doppi **non allineati** evidenzia i casi presenti nell'offset alternativo, utili come possibili indizi di segmentazione o come candidati separatori;
- la heatmap per blocchi da 100 caratteri mostra se le anomalie sono isolate oppure concentrate in specifiche zone del testo.


Questa rappresentazione è più utile nel contesto Playfair perché permette di valutare non solo la presenza dei doppi, ma anche il loro posizionamento nel crittogramma.

Numero doppi allineati offset 0: 29

Numero doppi non allineati / offset 1: 3

Primi doppi allineati offset 0: [(216, 'LL'), (268, 'LL'), (346, 'LL'), (376, 'NN'), (384, 'NN'), (390, 'HH'), (416, 'AA'), (456, 'AA'), (492, 'QQ'), (506, 'LL')]

Primi doppi non allineati / offset 1: [(7, 'II'), (49, 'GG'), (1403, 'LL')]



1.8.1 Lettura del diagramma di disposizione

Il diagramma mostra che i digrammi doppi allineati non sono soltanto un fenomeno numerico, ma hanno una specifica distribuzione lungo il crittogramma.

La timeline superiore evidenzia i doppi compatibili con l'allineamento principale. La timeline intermedia evidenzia invece i doppi rilevati nell'offset alternativo. La heatmap inferiore organizza le stesse anomalie in blocchi da 100 caratteri, rendendo più semplice individuare eventuali concentrazioni locali.

In ottica Playfair, questa analisi è importante perché il cifrario lavora su coppie di lettere. Se il testo fosse un Playfair standard perfettamente formato, ci si aspetterebbe una presenza molto ridotta, se non nulla, di digrammi doppi cifrati allineati. La loro presenza non esclude automaticamente Playfair, ma suggerisce cautela: possono essere in gioco una variante, una segmentazione diversa, caratteri di riempimento, errori di trascrizione o una trasformazione aggiuntiva.

1.9 9. Test di Kasiski

Il test di Kasiski cerca sequenze ripetute e analizza le distanze tra le loro occorrenze.

Nel caso di Vigenère, ripetizioni del testo in chiaro cifrate con la stessa porzione di chiave possono produrre sequenze ripetute nel crittogramma. Le distanze tra tali sequenze tendono quindi a essere multipli della lunghezza della chiave.

Dal punto di vista pratico, il test risponde alla domanda: **le ripetizioni presenti nel testo suggeriscono una periodicità?**

Se sì, quella periodicità può essere un indizio di cifratura polialfabetica.



Il risultato va comunque interpretato con cautela, perché sequenze sovrapposte o ripetizioni derivate dalla stessa porzione lunga possono sovrastimare alcuni fattori, soprattutto quelli piccoli come 2 o 4.

	Sequenza	Occorrenze	Prime_posizioni
12	FIN	7	[20, 321, 693, 759, 949, 1347, 1432]
160	GVD	7	[408, 488, 646, 782, 886, 902, 1018]
113	QZM	6	[227, 405, 779, 1047, 1257, 1301]
302	FINU	5	[20, 693, 759, 949, 1432]
24	IMN	5	[43, 53, 974, 1136, 1208]
13	INU	5	[21, 694, 760, 950, 1433]
75	LNy	5	[144, 287, 307, 665, 1404]
60	LWI	5	[112, 571, 673, 1206, 1412]
97	NTL	5	[185, 699, 843, 955, 1438]
343	NTLB	5	[185, 699, 843, 955, 1438]
9	QRC	5	[17, 690, 906, 946, 1429]
6	QVP	5	[14, 136, 687, 943, 1426]
98	TLB	5	[186, 700, 844, 956, 1439]
179	UGV	5	[487, 645, 885, 901, 1017]
378	UGVD	5	[487, 645, 885, 901, 1017]
16	VOL	5	[24, 583, 635, 655, 1157]
63	ANM	4	[116, 237, 257, 1061]
11	CFI	4	[19, 692, 948, 1431]

301	CFIN	4	[19, 692, 948, 1431]
478	CFINU	4	[19, 692, 948, 1431]

	Fattore	Occorrenze
0	2	817
1	4	438
2	3	378
3	5	265
4	8	259
5	7	225
6	10	218
7	6	204
8	16	165
9	21	155
10	11	149
11	22	126
12	23	121
13	12	119
14	9	99
15	14	91
16	17	88
17	13	81
18	18	81
19	19	67

	Distanza	Frequenza
0	739	189
1	256	128
2	483	90
3	110	74
4	389	50
5	673	37
6	190	37
7	1046	34
8	929	34
9	1412	34
10	578	22
11	588	19
12	72	19
13	88	19
14	921	18
15	468	18
16	20	14
17	102	13
18	1165	11
19	116	11



1.10 10. Indice di Coincidenza per sottosequenze

Per verificare l'ipotesi Vigenère si calcola l'IC medio delle colonne ottenute assumendo una lunghezza di chiave k .

Se k fosse corretto, ogni colonna dovrebbe essere cifrata con lo stesso alfabeto di sostituzione e quindi mostrare un IC più vicino a quello di una lingua naturale.

È importante osservare non solo la media, ma anche la dispersione tra colonne.


1.10.1 Come leggere questi indici



- **IC medio:** dà una stima della “naturalità media” delle colonne ottenute per un certo k .
- **IC minimo / massimo:** mostrano quanto le singole colonne si discostano tra loro.
- **IC_std:** è la deviazione standard; in termini informatici, misura la **stabilità** del risultato. Se è bassa, le colonne si comportano in modo più uniforme; se è alta, il candidato k è più instabile.

In pratica, un buon candidato di chiave non dovrebbe avere soltanto un IC medio alto, ma anche un comportamento relativamente coerente tra le colonne. Se i picchi sono piccoli o accompagnati da forte variabilità, il dato va considerato un indizio debole.

[16]:

	k	IC_medio	IC_min	IC_max	IC_std
	35 36	0.054537	0.035897	0.080769	0.010871
	25 26	0.054348	0.043506	0.082468	0.008719
	29 30	0.054065	0.041667	0.125887	0.015488
	17 18	0.053836	0.047222	0.066456	0.006829
	12 13	0.053603	0.045206	0.066924	0.005780
	9 10	0.053548	0.046743	0.065421	0.005116
	38 39	0.053462	0.037538	0.083926	0.011395
	31 32	0.053288	0.036364	0.077778	0.011261
	28 29	0.053139	0.039184	0.067755	0.007920
	19 20	0.053056	0.041080	0.071918	0.008002
	1 2	0.052927	0.051458	0.054397	0.002078
	20 21	0.052808	0.040921	0.069054	0.008012
	3 4	0.052804	0.047290	0.056366	0.003913
	34 35	0.052782	0.037805	0.080139	0.010735
	13 14	0.052772	0.047021	0.061869	0.004425





1.11 11. Lettura delle ipotesi

1.11.1 Trasposizione semplice

Una trasposizione conserva le frequenze del testo originale. Se la distribuzione del crittogramma è sensibilmente più piatta rispetto a italiano/inglese, l'ipotesi di pura trasposizione si indebolisce.

1.11.2 Sostituzione monoalfabetica

Una sostituzione monoalfabetica conserva la forma della distribuzione, ma cambia le etichette. Il confronto per ranking permette di valutare se la forma osservata è compatibile con una lingua

naturale.

1.11.3 Vigenère / polialfabetico

Un IC intermedio può essere compatibile con un cifrario polialfabetico. Tuttavia la lunghezza della chiave deve emergere da una convergenza tra Kasiski e IC per sottosequenze. Se i due test non convergono o i picchi sono poco marcati, l'ipotesi resta possibile ma non conclusiva.

1.11.4 Playfair / cifrario a digrammi

L'assenza della **J** e l'uso apparente di un alfabeto a 25 lettere sono elementi compatibili con Playfair. La verifica più importante è l'analisi dei digrammi allineati e dei digrammi doppi allineati.

```
[18]: {'lunghezza': 1448,
      'lettere_assenti': ['J'],
      'top_5_lettere': [{'Lettera': 'N', 'Freq_%': 9.185082872928177},
                        {'Lettera': 'L', 'Freq_%': 8.425414364640885},
                        {'Lettera': 'I', 'Freq_%': 7.872928176795579},
                        {'Lettera': 'C', 'Freq_%': 6.629834254143646},
                        {'Lettera': 'M', 'Freq_%': 6.560773480662983}],
      'ic_globale': 0.0523544616982364,
      'entropia': 4.4084612713872,
      'top_5_fattori_kasiski': [{'Fattore': 2, 'Occorrenze': 817},
                                {'Fattore': 4, 'Occorrenze': 438},
                                {'Fattore': 3, 'Occorrenze': 378},
                                {'Fattore': 5, 'Occorrenze': 265},
                                {'Fattore': 8, 'Occorrenze': 259}],
      'top_5_k_per_ic': [{'k': 36,
                          'IC_medio': 0.05453668959766521,
                          'IC_std': 0.010871289109444265},
                        {'k': 26, 'IC_medio': 0.05434750434750435, 'IC_std': 0.008719081556522472},
                        {'k': 30, 'IC_medio': 0.054065349544072945, 'IC_std': 0.01548806922751671},
                        {'k': 18, 'IC_medio': 0.053835668767689394, 'IC_std': 0.0068294704575922105},
                        {'k': 13, 'IC_medio': 0.0536027036027036, 'IC_std': 0.005779670628166387}],
      'digrammi_doppi_allineati_offset_0': 29,
      'digrammi_doppi_allineati_offset_1': 3}
```

1.12 12. Conclusione dell'analisi

L'analisi statistica consente di formulare una valutazione prudente.

Il crittogramma mostra una struttura non casuale, ma le frequenze non risultano pienamente compatibili con una semplice trasposizione o con una sostituzione monoalfabetica immediata. L'Indice di Coincidenza globale si colloca in una fascia intermedia, suggerendo una trasformazione che tende ad appiattire la distribuzione delle lettere.

L'ipotesi Vigenère, o più in generale polialfabetica, resta compatibile, ma deve essere trattata con cautela: la lunghezza della chiave dovrebbe essere supportata dalla convergenza tra Kasiski e IC per sottosequenze. In assenza di picchi netti e stabili, non è metodologicamente corretto assegnare con sicurezza una lunghezza di chiave.

La mancanza della lettera **J** è un indizio non trascurabile. Essa è compatibile con un alfabeto a 25 lettere e quindi con cifrari basati su matrice 5×5 , tra cui Playfair. Per questo motivo l'indagine è stata orientata verso Playfair o sue possibili varianti.

L'analisi della disposizione dei digrammi doppi mostra tuttavia che l'ipotesi Playfair standard va trattata con attenzione: la presenza di doppi allineati rappresenta un'anomalia che richiede ulteriori verifiche. Il punto non è quindi assumere automaticamente Playfair, ma usarlo come pista prioritaria da approfondire, valutando segmentazione, filler, possibili varianti e compatibilità linguistica del testo risultante.

In sintesi, l'analisi orienta l'indagine verso cifrari più complessi di una semplice trasposizione, con particolare attenzione a:

1. cifrari a digrammi, in particolare Playfair o varianti;
2. cifrari polialfabetici;
3. eventuali trasformazioni aggiuntive o irregolarità di segmentazione.

La fase successiva dovrebbe consistere in attacchi mirati al Playfair, mantenendo comunque aperta la verifica comparativa con le ipotesi polialfabetiche.

ANALISI CRITTOANALITICA - REPORT SINTETICO

Lunghezza del crittogramma normalizzato: 1448

Lettere assenti: ['J']

IC globale: 0.05235

Entropia osservata: 4.40846

Prime 5 lettere per frequenza:

Lettera	Conteggio	Freq_%
N	133	9.185083
L	122	8.425414
I	114	7.872928
C	96	6.629834
M	95	6.560773

Primi 5 fattori Kasiski:

Fattore	Occorrenze
2	817
4	438
3	378
5	265
8	259

Primi 5 valori k per IC medio:

k	IC_medio	IC_std
36	0.054537	0.010871
26	0.054348	0.008719
30	0.054065	0.015488
18	0.053836	0.006829

13 0.053603 0.005780

Numero doppi allineati offset 0: 29

Numero doppi non allineati / offset 1: 3

Osservazione:

L'assenza della J è un indizio non trascurabile e rende opportuno approfondire l'ipotesi di un cifrario basato su alfabeto a 25 lettere, in particolare Playfair o una sua variante.

Conclusione:

L'analisi non consente ancora una classificazione definitiva. Tuttavia, indebolisce la pura trasposizione, non privilegia in modo conclusivo Vigenère e orienta l'approfondimento verso Playfair o varianti a digrammi, pur segnalando come criticità la presenza di doppi allineati.

Report salvato in: grafici_analisi_crittogramma/report_sintetico_analisi.txt